

Verbesserte Objekterkennung auf Formularen mit synthetischen Daten und Self-Training

Okan Yakin

Technische Universität Dortmund

Abschlusspräsentation der Bachelorarbeit

Motivation: Formulare sind überall

Formulare sind in vielen Bereichen unverzichtbar

Gesundheitswesen, Finanzen und Verwaltung

[illegible]

Rechnung

[illegible]

Haushaltsplan

March 28, 1989
 Chicago, Illinois
 Pittsburgh

NEW BRAND _____	FLAVOR: ☐ Maltol ☐ Nicotined	RETAIL _____
OTHER BRAND _____	☐ Full ☐ Light	

LENGTH _____	SER: ☐ Freebird	AGE: ☐ 18-25 ☐ 26-35 ☐ 36-45	RACE: ☐ White ☐ Black ☐ Other _____	CIRCUMSTANCES: ☐ Single ☐ Married ☐ Together (hus/wife)
--------------	--	--	---	---

Scenarios

NAME: _____

ADDRESS: _____

PHONE: _____

SCENARIO'S NAME: _____

ASK TO SPEAK TO A FEMALE IN THE HOUSEHOLD WHO IS 18 OR OLDER

OF AGE: _____

Today, we want to know _____ how _____ We are conducting a survey
 which gives consumers a place and time to express their views on the
 new brand you gave us and we are thankful for the role of any products or services.

A subject insight, Inc.
 665297591

Fragebogen

[illegible]

handschriftliches
Formular

Bildquelle: RVL-CDIP-Datensatz [2]


Warum Textregionen automatisch erkannt werden sollen

Durchgängige Automatisierung

- ▶ Formulare werden als ganze Seiten erfasst.
- ▶ Vor OCR und Analyse müssen Textregionen lokalisiert werden.
- ▶ Manuelle Boxen bremsen die Automatisierung.

Ziel dieser Arbeit

- ▶ Textregionen automatisch erkennen
- ▶ zusätzliche manuelle Annotationen minimieren



Je weniger manuelle Zwischenschritte nötig sind, desto besser lässt sich die gesamte Verarbeitung automatisieren.

Aufgabe: Textregionen statt Feldbedeutungen

Beispielhafte Bounding Boxes um Textregionen

REQUEST REQUEST FROM TAB BY <u>INTERNATIONAL LICENSES OPERATION</u>		RECEIVED <u>APR 2 1984</u> <u>P.H.H.</u>
REQUEST NO.:	1-42	
DATE:	March 27, 1984	
INITIATED BY:	P. W. HARRIS <i>PHH</i>	
COMPLAINT:		
WANTED DATE:	April 13, 1984	
COUNTRY:	JERUSALEM	
PRIORITY:	LARRY STEIN, Filler and VICTORY	
NAME OF WIFE:		
Advice if locally obtained Vatican Money (sample enclosed) is an acceptable substitute for Vatican		
ADD COMMENTS: <i>Original Ltr. to the PWA 24MAR-84</i>		
BY:		
DATE:		
OFFICE:		
1) Nature of work should be specified in exact terms. 2) Add completion date if completion date cannot be met. 3) Two copies of this form to be sent to TAB by initiative and TAB is to return by T-5, one completed copy.		
NO. 420		
2037/115 123456		620429180

Annotationsbeispiel aus FUNSD [1]

Erkennungsziel

- ▶ eine Klasse: text
- ▶ eine Bounding Box je zusammenhängendem Textabschnitt
- ▶ keine Klassen für Name, Datum oder Adresse

**Erkannt wird die Position des
Textes; seine Bedeutung wird erst
später ausgewertet.**

Herausforderung: Annotationsaufwand und Realitätslücke

Manuelle Annotationen sind teuer

- ▶ Jede Textregion benötigt eine Bounding Box.
- ▶ Bounding Boxes müssen gezeichnet und geprüft werden.
- ▶ Neue Formulartypen erzeugen neuen Aufwand.

Synthetisch und real unterscheiden sich

- ▶ Synthetische Seiten liefern Boxen automatisch.
- ▶ Reale Seiten enthalten mehr Schriften, Handschrift, Logos und Scanrauschen.
- ▶ Ein rein synthetisch trainiertes Modell überträgt sich daher nicht vollständig.

Gesucht wird ein Verfahren, das reale Seiten nutzt, ohne für jede neue Seite manuelle Boxen zu verlangen.

Datengrundlage: FUNSD

 Revised/Revised Tables La
6
Revised

**Allowable Grade Substitutions
for Export CPCL**

Standard Grade Mark	Allowable Substitutions
PCFS Fine cured fines	RPCFS or RPCFS-O
PCBS Buggy fines	RPCBS or RPCBS-O
	WCC
MC-4 Manufacturing fines	MC-4-S
	MC-4-PH
	MC-4-RC
	MC-4-W
MC-6 Stem Moist	MC-1
MC-7 Winnowers	C Stem
RXF Fine fine cured stems	RXF or RDXF-O
	RFXM-S
	RFXM-T
RBF Fine Buggy stems	RBF or RBSF-O
	RBS-S
	RBS-L
	RBS-T

Form Understanding in Noisy Scanned Documents


- ▶ 199 vollständig annotierte Formulare
- ▶ 149 Trainings- und 50 Testformulare
- ▶ gerasterte Dokumente mit 100 dpi
- ▶ reales Druck- und Scanrauschen

Verwendung in dieser Arbeit

- ▶ synthetische Seiten aus Trainingslayouts
- ▶ Auswertung auf dem realen Testsatz

Quelle: FUNSD-Datensatz [1].

Erzeugung synthetischer Trainingsseiten



1. Vorhandene FUNSD-Boxen bestimmen die zu verändernden Textregionen.
2. Inpaint Anything entfernt den ursprünglichen Text und rekonstruiert den Hintergrund.
3. Wikipedia-Text wird passend umbrochen und in die Regionen eingesetzt.
4. Die neuen Bounding Boxes werden automatisch gespeichert.

Quelle: Erzeugungsablauf dieser Arbeit; Inpaint Anything [5].

Detektor: Faster Region-Based Convolutional Neural Network




Abbildung nach Ren et al. [3].

1. Feature Extraction

ResNet-50 berechnet lokale Features; das FPN stellt mehrere Skalen bereit.

2. Region Proposals

Das RPN erzeugt Kandidatenbereiche, die wahrscheinlich Text enthalten.

3. RoI Align

Features unterschiedlich großer Proposals werden vereinheitlicht.


4. Classification und Box Regression

Text oder Hintergrund; Position und Größe der Bounding Box werden angepasst.

5. Final Detections

NMS entfernt stark überlappende doppelte Predictions.

Wie entstehen Region Proposals?



Ren et al. [3], Fig. 3 (Ausschnitt; Paper-Konfiguration).


Die Grafik wird von unten nach oben gelesen.

1. **Feature Map und Sliding Window**
Das kleine Netz wird an jede räumliche Position gesetzt.
2. **k Anchor Boxes**
Ausgangsboxen decken verschiedene Größen und Seitenverhältnisse ab.
3. **Objectness**
Für jeden Anchor wird Objekt oder Hintergrund geschätzt.
4. **Box Regression**
Vier Werte verschieben und skalieren den Anchor zu einem Proposal.
5. **Auswahl**
Hohe Scores bleiben; NMS entfernt stark überlappende Proposals.

Das RPN erzeugt Kandidatenboxen; die endgültige Klassenentscheidung folgt im Detection Head.

Auswertung der Erkennungen

Kennzahl	Bedeutung
Precision	Anteil der Predictions, die richtig sind
Recall	Anteil der Ground Truth Bounding Boxes, die gefunden werden
F1	harmonisches Mittel aus Precision und Recall




$$\text{IoU} = \frac{\text{Intersection Area}}{\text{Union Area}}$$

Match bei $\text{IoU} \geq 0,5$

Quelle: IoU-Grenzwert entsprechend der FUNSD-Auswertung [1].


Self-Training: Teacher und Student



- ▶ Der Teacher erzeugt Pseudo-Labels für reale, nicht annotierte Seiten.
- ▶ Der Student lernt aus synthetischen Seiten mit Ground Truth und realen Seiten mit Pseudo-Labels.
- ▶ Die ursprünglichen synthetischen Daten bleiben in jeder regulären Runde erhalten.

Reale Daten werden nutzbar, ohne für jede Seite neue manuelle Bounding Boxes zu zeichnen.


ASTOD: fünf Schritte einer Runde



- ▶ Mehrere Ansichten: Original, Spiegelung, Vergrößerung sowie Spiegelung + Vergrößerung.
- ▶ Predictions werden zurücktransformiert und mit NMS zusammengeführt.
- ▶ Der Adaptive Threshold wird aus dem Histogramm der Confidence Scores bestimmt.
- ▶ Unsichere Pseudo-Labels erhalten im Loss ein geringeres Gewicht.

Quelle: ASTOD [4].

Übertragung von ASTOD auf diese Arbeit



Zuordnung in dieser Arbeit

- ▶ Labeled Data → synthetische Seiten mit Ground Truth
- ▶ Unlabeled Data → reale FUNSD-Trainingsseiten
- ▶ Student → beide Datengruppen
- ▶ Refinement → erneut nur synthetische Daten

Wichtige Abweichung

- ▶ ASTOD nimmt dieselbe Datenverteilung an.
- ▶ Hier wird eine Lücke zwischen synthetischen und realen Daten überbrückt.

Versuchsaufbau

Komponente	Einstellung
Detektor	Faster R-CNN mit ResNet-50-FPN
Erkennungsklasse	text; Hintergrund wird intern behandelt
Optimizer	SGD
Evaluation	Precision, Recall und F1 bei IoU = 0,5
Initial Teacher	auf synthetischen Seiten trainiert
Self-Training	synthetische Ground Truth + reale Pseudo-Labels

Detektor und Auswertung bleiben in den Hauptvergleichen gleich; verändert wird die Trainingsstrategie.

Hyperparameter Search

Fragestellung: Welche stabile Optimizer-Einstellung wird für die folgenden Vergleiche verwendet?

Ausgangspunkt und Anpassung

- ▶ Ausgangswerte orientieren sich an FUNSD und Faster R-CNN.
- ▶ In dieser Arbeit werden mehrere Werte systematisch verglichen.
- ▶ Danach bleibt eine Einstellung für die Hauptversuche fest.

FUNSD liefert den Ausgangspunkt; die endgültigen Werte stammen aus der eigenen Hyperparameter Search.

Gewählte Einstellung

Parameter	Wert
Learning Rate	0,006
Momentum	0,8
Weight Decay	0,0005

- ▶ Learning Rate: Stärke der Gewichtsänderung
- ▶ Momentum: glättet die Update-Richtung
- ▶ Weight Decay: begrenzt zu große Gewichte

Quelle: Ausgangswerte nach FUNSD [1] und Faster R-CNN [3]; Auswahl durch eigene Versuche.

Ausgangsleistung ohne Self-Training

Fragestellung: Wie groß ist die Lücke vor dem Self-Training?


Trainingsdaten	Precision	Recall	F1
nur synthetische Daten	0,65	0,76	0,70
nur reale Annotationen	0,78	0,83	0,80

Auswertung: reale FUNSD-Testformulare

Das synthetisch trainierte Modell liegt etwa 0,10 F1 unter dem Modell mit realen Annotationen.


Entwicklung über viele Self-Training-Runden

Fragestellung: Wie verändert sich die Leistung über weitere Teacher-Student-Runden?




F1 steigt von etwa 0,708 auf 0,773. Der größte Zuwachs entsteht früh; danach folgt ein Plateau.

Zwei Varianten der synthetischen Seiten



Rekonstruierter Hintergrund

Der alte Text wird entfernt; neuer Text wird direkt in den rekonstruierten Bereich eingesetzt.



Weißer Hintergrund

Die ursprüngliche Textregion wird vor dem Einsetzen des neuen Textes durch ein weißes Rechteck ersetzt.

Vergleich der Erzeugungsverfahren

Fragestellung: Hilft der erhaltene Scan-Hintergrund bei der Übertragung auf reale Formulare?

Verfahren	F1	Einordnung
rekonstruierter Hintergrund / direktes Einfügen	0,76	erhält den Kontext des Scans
weißer Hintergrund	0,75	einfacher, erzeugt aber auffällige weiße Flächen

Direktes Einfügen in den rekonstruierten Hintergrund ist leicht besser; der Unterschied bleibt klein.

Einfluss der Menge synthetischer Daten

Fragestellung: Wie viele synthetische Seiten werden für nützliches Self-Training benötigt?

Synthetischer Anteil	F1	Ergebnis
10%	0,72	Self-Training liefert weiterhin einen Nutzen
25%	0,75	bereits nahe an längeren Läufen mit allen Daten
100%	0,77	stärkstes Ergebnis im langen Lauf

Auch kleinere Teilmengen sind nutzbar; der vollständige lange Lauf erreicht das stärkste Ergebnis.

Ablation: synthetische Daten entfernen

Fragestellung: Kann die synthetische Grundlage nach Erreichen des Plateaus entfallen? Fünf starke Checkpoints aus dem Plateau werden auf zwei Arten verglichen:

Checkpoint	Regular F1	Pseudo-only F1	Differenz
81	0,7726	0,7680	-0,0045
56	0,7710	0,7633	-0,0077
77	0,7709	0,7595	-0,0114
75	0,7708	0,7601	-0,0107
78	0,7698	0,7548	-0,0150

- ▶ **Regular:** Student lernt aus synthetischen Seiten und realen Pseudo-Labels; danach folgt synthetisches Refinement.
- ▶ **Pseudo-only:** Ab dem gewählten Checkpoint bleiben nur reale Pseudo-Labels; das Refinement entfällt.

Das Entfernen der synthetischen Daten senkt F1 in allen getesteten Fortsetzungen.

Synthetische Daten bei realer Aufsicht

Fragestellung: Helfen synthetische Daten noch, wenn reale Annotationen vorhanden sind?

Trainingsstrategie	F1
nur reale Annotationen	0,8011
reale + synthetische Daten im direkten Training	0,8007
reale + synthetische Daten über Self-Training	0,8144

Direktes Mischen liefert keinen Gewinn; die Einbindung über Self-Training verbessert F1 geringfügig.

Zentrale Ergebnisse

1. Nur synthetische Daten erreichen **0,70 F1**; reale Annotationen **0,80 F1**.
2. Synthetisch-reales Self-Training erhöht F1 auf **0,77**.
3. Das Entfernen der synthetischen Grundlage verschlechtert die getesteten Fortsetzungen.
4. Mit realen Annotationen erreicht synthetisch unterstütztes Self-Training **0,814 F1**.

Self-Training verkleinert die Lücke zwischen synthetischen und realen Daten, ersetzt reale Annotationen aber nicht vollständig.

Grenzen der Untersuchung

- ▶ Auswertung auf einem Formular Datensatz und einer Erkennungsklasse
- ▶ Wiederverwendung annotierter Ausgangslayouts für synthetische Seiten
- ▶ begrenzte Variation bei Schriftarten und Handschrift
- ▶ keine Mittelung über mehrere unabhängige Zufallsinitialisierungen
- ▶ kein eigener Validierungssatz für die Modellauswahl

Fazit und Ausblick

Fazit

- ▶ Synthetische Daten bilden einen brauchbaren automatischen Ausgangspunkt.
- ▶ Self-Training nutzt reale Seiten ohne zusätzliche manuelle Boxen.
- ▶ Die synthetische Ground Truth stabilisiert die wiederholten Trainingsrunden.
- ▶ Reale Annotationen liefern weiterhin die stärkste Aufsicht.

Ausblick

- ▶ realistischere Schriften, Handschrift und Layoutvariation
- ▶ weitere Datensätze und neuere Detektoren
- ▶ mehrere Zufallsinitialisierungen und eigener Validierungssatz

Literatur

1. G. Jaume, H. K. Ekenel und J.-P. Thiran, "FUNSD: A Dataset for Form Understanding in Noisy Scanned Documents", ICDAR Workshops, 2019.
2. A. W. Harley, A. Ufkes und K. G. Derpanis, "Evaluation of Deep Convolutional Nets for Document Image Classification and Retrieval", ICDAR, 2015.
3. S. Ren, K. He, R. Girshick und J. Sun, "Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks", IEEE TPAMI, 2017.
4. R. Vandeghen et al., "Adaptive Self-Training for Object Detection", ICCV Workshops, 2023.
5. T. Yu et al., "Inpaint Anything: Segment Anything Meets Image Inpainting", arXiv:2304.06790, 2023.